

Universidade Federal do Rio Grande do Norte
Departamento de Engenharia da Computação e
Automação

DCA 3606 - Inteligência Artificial

Alunos:

1. Carlos Gabriel Medeiros da Silva
2. Daniel Bruno Trindade da Silva
3. Joanderson Luan da Silva Linhares
4. Maria Clara Moura de Freitas

Diagnóstico de Retinopatia Diabética utilizando Redes
Neurais Convolucionais (CNN)

1. Introdução

A Retinopatia Diabética (RD) é uma complicação vascular do diabetes que afeta os olhos, sendo uma das principais causas de cegueira em adultos em idade ativa. O diagnóstico tradicional depende da análise manual de imagens do fundo do olho por oftalmologistas, um processo demorado, subjetivo e sujeito à fadiga humana.

Com o avanço da Inteligência Artificial, especificamente na área de Visão Computacional, tornou-se possível automatizar essa triagem com alta precisão. Diferente de abordagens baseadas em regras manuais (como a Lógica Fuzzy), o Aprendizado Profundo (*Deep Learning*) permite que o computador aprenda padrões complexos diretamente dos pixels da imagem.

Este projeto tem como objetivo desenvolver, treinar e validar uma Rede Neural Convolucional (CNN) capaz de classificar imagens de retina em duas categorias: "Saudável" e "Retinopatia Diabética", visando criar um sistema robusto de suporte à decisão médica.

2. Metodologia

O desenvolvimento do projeto foi realizado na linguagem Python, utilizando a biblioteca TensorFlow/Keras para a construção da rede neural, além de Matplotlib, Numpy e Scikit-learn para manipulação de dados e métricas.

2.1. Conjunto de Dados (Dataset)

O modelo foi treinado com um conjunto de imagens de fundoscopia digital. As imagens foram divididas em três subconjuntos:

- **Treinamento:** Utilizado para o ajuste dos pesos da rede.
- **Validação:** Utilizado para monitorar o desempenho e evitar *overfitting*.
- **Teste:** Conjunto inédito reservado para a avaliação final.

2.2. Pré-processamento

Antes de serem inseridas na rede, as imagens passaram por um processo de normalização (*rescaling*), onde os valores dos pixels foram convertidos para o intervalo [0, 1]. O tamanho de entrada foi padronizado em 224x224 pixels (RGB).

2.3. Arquitetura da CNN

A arquitetura proposta foi construída utilizando o modelo Sequential do Keras, composta por camadas de extração de características e classificação:

1. **Blocos Convolucionais:** Foram implementados 4 blocos de convolução para capturar hierarquias de características (de bordas simples a lesões complexas). O número de filtros dobrou progressivamente:
 - Bloco 1: 8 filtros (3x3), ativação ReLU + MaxPooling2D.
 - Bloco 2: 16 filtros (3x3), ativação ReLU + MaxPooling2D.
 - Bloco 3: 32 filtros (3x3), ativação ReLU + MaxPooling2D.
 - Bloco 4: 64 filtros (3x3), ativação ReLU + MaxPooling2D.
2. **Camada Flatten:** Vetorização dos mapas de características 2D.
3. **Classificador Denso (Fully Connected):**
 - Camada oculta com 256 neurônios (ativação ReLU).
 - Camada de Dropout de 30% (0.3).
 - Camada de saída com 1 neurônio e função de ativação Sigmoid (classificação binária).

2.4. Implementação e Decisões de Projeto

Durante a implementação do código, enfrentamos desafios específicos que exigiram decisões técnicas de engenharia:

- **Combate ao Overfitting (Dropout):** Observou-se inicialmente que a rede decorava os dados de treino muito rápido. Para mitigar isso, foi

inserida uma camada de Dropout(0.30) antes da saída final, desligando aleatoriamente 30% dos neurônios durante o treino para forçar a rede a aprender características mais robustas.

- **Desbalanceamento de Classes (Class Weights):** Como datasets médicos frequentemente possuem mais exemplos saudáveis do que doentes, utilizamos a função `class_weight.compute_class_weight` do Scikit-learn. Isso gerou pesos automáticos para penalizar mais severamente o modelo quando ele erra uma imagem da classe minoritária (doença), equilibrando o aprendizado.
- **Otimização Refinada:** O modelo foi compilado com o otimizador Adam utilizando uma taxa de aprendizado (*learning rate*) baixa de 0.0001. Essa escolha garantiu uma convergência mais suave e estável da função de perda (*Binary Crossentropy*).
- **Métricas Estendidas:** Além da acurácia, o código foi instrumentado para monitorar AUC (Area Under Curve), Precision e Recall, métricas fundamentais para validar a confiabilidade de diagnósticos médicos.


3. Resultados

3.1. Desempenho no Treinamento

O treinamento foi executado monitorando a evolução das métricas. Conforme observado nos gráficos gerados (Figura 1 e Figura 2), o modelo demonstrou um aprendizado consistente:


- **Acurácia:** A curva de validação acompanhou a de treino, estabilizando-se em patamares altos.
- **Perda (Loss):** A curva de perda decaiu suavemente sem divergir, validando a eficácia da *learning rate* reduzida e do *Dropout*.

Figura 1: Acurácia.



Fonte: Elaborado pelos Autores.

Figura 2: Perda (loss).



Fonte: Elaborado pelos Autores.

3.2. Avaliação no Conjunto de Teste

Após o treinamento, o modelo foi submetido ao conjunto de teste. Os resultados obtidos foram expressivos:

- **Loss (Perda):** 0.1706
- **Acurácia Final:** 95.23%


Este resultado coloca o modelo em um nível de performance muito superior a métodos baseados em limiares simples.

3.3. Matriz de Confusão

A análise da Matriz de Confusão (Figura 3) revela o comportamento do classificador:

- **Verdadeiros Negativos e Positivos:** A grande maioria das imagens foi classificada corretamente na diagonal principal.
- **Erros:** O número de falsos positivos e negativos foi baixo, demonstrando que a rede consegue distinguir bem entre retinas saudáveis e doentes, superando a dificuldade de variação de iluminação e ruído.

Figura 3: Matriz de confusão.



4. Discussão e Comparativo

Comparando esta abordagem com métodos clássicos (como a Lógica Fuzzy testada anteriormente, que obteve cerca de 80% de acerto), a CNN demonstrou superioridade clara, atingindo **95.23%** de acurácia.

Enquanto sistemas manuais dependem da definição explícita de "textura" ou "cor", a CNN, através de suas camadas convolucionais progressivas (8 a 64 filtros), aprendeu sozinha hierarquias de características que melhor separam as classes. A estratégia de usar *Class Weights* foi crucial para garantir que a rede não ignorasse os casos de doença.

5. Conclusão

O projeto atingiu seu objetivo com êxito. A implementação da Rede Neural Convolucional, ajustada com técnicas de regularização (*Dropout*) e balanceamento de classes, permitiu classificar imagens de Retinopatia Diabética com uma acurácia superior a 95%.

Conclui-se que o uso de Deep Learning é altamente viável para auxiliar no diagnóstico oftalmológico, servindo como uma ferramenta poderosa para triagem em larga escala, reduzindo a carga de trabalho de especialistas e agilizando o atendimento aos pacientes.