

Universidade Federal do Rio Grande do Norte

Departamento de Engenharia da Computação e Automação

DCA 3606 - Inteligência Artificial

Alunos:

1. Carlos Gabriel Medeiros da Silva
2. Daniel Bruno Trindade da Silva
3. Joanderson Luan da Silva Linhares
4. Maria Clara Moura de Freitas

Classificação de Retinopatia Diabética utilizando Lógica Fuzzy e Comparativo com Redes Neurais Convolucionais (CNN)

1. Introdução

A Retinopatia Diabética (RD) é uma das principais causas de cegueira em adultos, decorrente de danos aos vasos sanguíneos da retina causados pelo diabetes. O diagnóstico precoce é fundamental para evitar a perda de visão. No entanto, a análise manual de imagens de fundo de olho demanda tempo e especialistas qualificados.

Este projeto tem como objetivo desenvolver e avaliar um sistema de suporte à decisão baseado em **Lógica Fuzzy (Nebulosa)** para classificar imagens de retina em duas classes: "Negativo" (Saudável) e "Positivo" (Doente). Além disso, o trabalho visa comparar a eficácia desta abordagem baseada em regras com um modelo de Aprendizado Profundo (*Deep Learning*) utilizando Redes Neurais Convolucionais (CNN).

2. Metodologia e Desenvolvimento

O sistema foi desenvolvido em Python utilizando as bibliotecas **scikit-fuzzy**, **opencv** e **numpy**. O fluxo de trabalho foi dividido em três etapas principais: Análise Exploratória, Definição do Modelo Fuzzy e Validação.

2.1. Dataset e Pré-processamento

O conjunto de dados utilizado (*test set*) é composto por 375 imagens balanceadas:


- **Negativos (Saudáveis):** 186 imagens.


- **Positivos (Doentes):** 189 imagens.

Todas as imagens foram redimensionadas para 64x64 pixels para otimização computacional, e o canal Verde (G - Green) do espaço de cores BGR foi isolado, visto que este canal oferece o melhor contraste para identificação de estruturas retinianas.

2.2. Extração de Características e Análise Exploratória

Inicialmente, foram consideradas duas variáveis de entrada: a Intensidade Média do Verde e o Desvio Padrão (Textura). Para validar essas escolhas, foi gerado um gráfico de dispersão (*scatter plot*) dos dados reais.





Diagnóstico dos Dados:

A análise do gráfico de dispersão revelou um comportamento contra-intuitivo, mas decisivo:

1. **Média Verde (Feature 1):** Apresentou alta sobreposição entre as classes, tornando-se irrelevante para a classificação.
2. **Desvio Padrão/Textura (Feature 2):** Mostrou-se um discriminante forte. Observou-se que, neste dataset específico, as retinas saudáveis apresentavam maior desvio padrão (maior contraste/textura), enquanto as retinas doentes tendiam a ter desvio padrão menor (imagens mais "suaves" ou borradas, possivelmente devido a exsudatos ou perda de definição vascular).

Com base nisso, aplicou-se o princípio da Navalha de Ockham, simplificando o modelo para utilizar apenas o **Desvio Padrão** como variável de entrada.

2.3. Modelagem Fuzzy (Mamdani e Sugeno)

Foram implementados dois controladores Fuzzy:

1. **Mamdani:** Utiliza funções de pertinência trapezoidais e triangulares para entrada e saída, com defuzzificação por centróide.
2. **Sugeno (Ordem Zero):** Utiliza as mesmas entradas, mas a saída é composta por constantes (Singletons), sendo computacionalmente mais leve.

Regras de Inferência (Calibradas pelos Dados):

- Se *Desvio Padrão* é Baixo (Pertinência à classe "baixo_doente") **Então** Risco é Alto.
- Se *Desvio Padrão* é Alto (Pertinência à classe "alto_saudavel") **Então** Risco é Baixo.

O ponto de corte (limiar) observado visualmente no histograma de distribuição foi próximo a 15.

3. Resultados da Abordagem Fuzzy


Ambos os sistemas (Mamdani e Sugeno) convergiram para os mesmos resultados, dado que o sistema foi reduzido a uma única variável de forte correlação.

3.1. Métricas de Desempenho

- **Total de Imagens:** 375
- **Acertos:** 296
- **Acurácia Global:** 78.93%

3.2. Análise de Erros (Matriz de Confusão)

A matriz de confusão abaixo detalha o comportamento do classificador:



- **Falsos Negativos (28):** O sistema classificou 28 imagens doentes como saudáveis. Isso ocorre na "zona cinzenta" do histograma, onde retinas doentes apresentaram textura atipicamente alta.
- **Falsos Positivos (51):** O sistema classificou 51 imagens saudáveis como doentes. Isso indica que o modelo é ligeiramente conservador, tendendo a classificar imagens de baixo contraste como patológicas.

4. Estudo Comparativo: Fuzzy vs. CNN

Para contextualizar o desempenho do sistema Fuzzy, comparamos os resultados com uma Rede Neural Convolucional (CNN) treinada no mesmo dataset.

4.1. Tabela Comparativa

Métrica	Lógica Fuzzy (Proposta)	CNN (Benchmark)
Acurácia	78.93%	88.00%
Precision (Macro)	N/A*	0.88
Recall (Macro)	N/A*	0.88
F1-Score	N/A*	0.88
Tipo de Aprendizado	Baseado em Regras (White-box)	Aprendizado de Máquina (Black-box)

*Precision/Recall do Fuzzy podem ser derivados da matriz: Precision (Pos) = 0.76, Recall (Pos) = 0.85.

4.2. Discussão

A CNN obteve um desempenho superior (88%) em relação ao Fuzzy (79%). Essa diferença de aproximadamente 9 pontos percentuais pode ser explicada pela natureza das tecnologias:

- Capacidade de Extração:** O sistema Fuzzy dependeu de uma característica "feita à mão" (*hand-crafted feature*) — a textura global. Se a doença se manifestar apenas por pequenas manchas vermelhas (microaneurismas) sem alterar a textura global da imagem, o Fuzzy falha. A CNN, por outro lado, aprende filtros espaciais que detectam bordas, formas, cores e padrões complexos automaticamente.
- Explicabilidade (XAI):** Embora a CNN seja mais precisa, ela atua como uma "caixa preta". O sistema Fuzzy oferece vantagem na **interpretabilidade**. Podemos afirmar categoricamente que o erro em 21% dos casos se deveu ao fato de aquelas imagens possuírem um desvio padrão ambíguo. Na medicina, saber o *porquê* da decisão é, às vezes, tão importante quanto a decisão em si.

5. Conclusão

O desenvolvimento deste trabalho demonstrou que é possível construir um classificador competente (quase 80% de acerto) utilizando Lógica Fuzzy com regras simples e intuitivas, desde que haja uma análise estatística prévia robusta dos dados. A descoberta de que a textura (Desvio Padrão) era o principal discriminante permitiu simplificar o modelo e garantir sua eficácia.

A comparação com a CNN reforça que, para tarefas de visão computacional bruta, o Aprendizado Profundo é o estado da arte devido à sua capacidade de generalização. No entanto, o sistema Fuzzy provou ser uma alternativa válida para triagem inicial ou para cenários onde o poder computacional é limitado e a explicabilidade das regras é prioritária.